

半参数模型的影响函数

嘉树

2026 年 3 月

说明：本文是对「影响函数」(influence function) 的介绍，讲述了它在半参数模型中扮演的角色，并以构造正交矩条件为例展示了其威力。影响函数本质上是对「梯度」概念在泛函空间中的推广，刻画了分布扰动对估计量的一阶影响。由此，它是分析估计量效率、对模型误设的稳健性等性质的利器。

1 影响函数的定义

我们考虑半参数意义上的估计量，即那些依赖于对非参数部分估计的对参数的估计量。记 $\hat{\theta}$ 就是一个半参数意义的估计量，它是数据 $W_1, \dots, W_n$ 的函数。我们始终假设数据是独立同分布的，且有一个累积分布函数 F_0 。当 F_0 是数据 W_i 的累积分布函数时，记 θ_0 是 $\hat{\theta}$ 的概率极限。

我们关注的是这样一类线性估计量，满足如下的渐进展开^❶

$$\sqrt{n}(\hat{\theta} - \theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi(W_i) + o_p(1)$$

其中 $\psi(\cdot)$ 满足

$$\mathbb{E}[\psi(W)] = 0 \quad \text{和} \quad \mathbb{E}[\psi(W)' \psi(W)] < \infty$$

于是 $\hat{\theta}$ 的渐进方差就是 $\mathbb{E}[\psi(W)\psi(W)']$ 。函数 $\psi(\cdot)$ 就被称为「影响函数」(influence function)^❷，它描述了每个数据点对估计量的影响，同时我们还将看到，它也刻画了数据分布的一个微小扰动对 $\hat{\theta}$ 的概率极限的影响。有许多 $\sqrt{n}$ 一致的估计量都有这样的渐进线性展开，如 M 估计量、Z 估计量等。

其实影响函数不一定需要通过渐进展开来构造。设 F 是任意分布（只需满足一些正则条件），令 $\theta(F)$ 表示估计量 $\hat{\theta}$ 在数据的累积分布函数为 F 时的概率极限。由此 $\theta(F)$ 就刻画了当模型误设时，估计量会收敛到什么伪真值。为了研究分布的微小扰动，我们考虑一个参数化的分布族 $\{F_\beta\}$ ，当 $\beta = 0$ 时， $F_\beta = F_0$ 。得分函数（对数似然函数关于参数 β 在 $\beta = 0$ 处的导数）表示为 $S_\beta(w)$ 。可以证明，影响函数 $\psi(W)$ 满足如下微分方程^❸

$$\left. \frac{\partial \theta(F_\beta)}{\partial \beta} \right|_{\beta=0+} = \mathbb{E}_{F_0}[\psi(W)S_\beta(W)]$$

其中期望是关于分布 F_0 的。可以通过求解这个微分方程得到影响函数。

Ichimura and Newey (2022) 展示了一种更方便的求解影响函数的方法，他们使用 Gâteaux 导数来定义泛函微分。设 H 是一个累积分布函数，考虑分布扰动 $F_\tau = (1 - \tau)F_0 + \tau H$ ，其中 $\tau \in [0, C)$ ， $C \in (0, 1)$ 是某个常数。 F_τ

❶ 严格来说，除了渐进线性展开，我们还要求估计量 $\hat{\theta}$ 是正则的，粗略的含义是：让真实分布 F_0 产生微小扰动后，估计量的极限分布保持不变，见 (1) 的定义。满足正则性和渐进线性展开的估计量被称为正则渐进线性估计量 (regular asymptotically linear estimator, RAL)。

❷ 这其实是一个稳健统计学中的经典概念，最早来自 Hampel (1974)。核心思想就是看数据分布的一阶扰动对估计量的影响，和半参数效率理论有紧密而深刻的联系。

❸ $\theta(F_\beta)$ 是关于分布 F_β 的泛函，其导数定义为 $\lim_{\beta \rightarrow 0+} \beta^{-1}[\theta(F_\beta) - \theta(F_0)]$ ，它的存在性依赖于前面所说的正则渐进线性条件（还潜在地依赖于二次均值可微条件，见技术附录），当这个条件满足时，导数就存在，且一定可以表示成影响函数和得分函数的内积，见 van der Vaart (1991) 的引理 A.1 或 Newey (1994) 的定理 2.1。我们还可以更进一步，我们可以将这个泛函的导数看作是切空间（因为得分函数属于切空间）上的泛函，那么根据 Riesz 表示定理，存在该切空间上的一个唯一的元素 ψ^* ，使得此泛函可以表示成 ψ^* 和得分函数的内积。这个 ψ^* 就是「有效率的影响函数」(efficient influence function, EIF)。其他的影响函数在切空间上的投影就是 ψ^* 。

的意思是说，数据大部分来自于 F_0 ，但有很小的概率 τ 来自于 H ^④。设对选定的 H ， $\theta(F_\tau)$ 存在且关于 τ 可导（导数就是 Gâteaux 导数），则影响函数 $\psi(W)$ 满足

$$\left. \frac{d\theta(F_\tau)}{d\tau} \right|_{\tau=0+} = \int \psi(w)H(dw) = \mathbb{E}_H[\psi(W)]$$

其中 $\mathbb{E}[\psi(W)] = 0$ 且 $\mathbb{E}[\psi(W)^2] < \infty$ 。上式左边就衡量了一个轻微污染的分佈对于估计量的极限值的影响，等式右边定义了一个线性泛函。

④ 这种形式的分佈扰动来自 Hampel (1974)。可以证明这种偏离路径是二次均值可微的。

2 影响函数的威力：以构造正交矩条件为例

泛函导数 $d\theta(F_\tau)/d\tau$ 及影响函数是一个大有可为的概念级工具。首先其基本含义是，它衡量了分佈 F_τ 的局部扰动对 $\theta(F_\tau)$ 的影响。我们可以赋予它经济学上的意义，譬如，它可以表示数据分佈的局部变化带来的政策效应；又如，当 $\theta(F_\tau)$ 是一个估计量的概率极限时，这个导数就可以看作模型误设对估计量的影响，从而可以应用在估计量的局部敏感性和稳健性分析中；再如，当 $\theta(F_\tau)$ 是矩条件的期望时（在代入非参数估计量的概率极限后），影响函数可以被用来构造正交矩条件，正交的含义是矩条件的成立不受对非参数部分的估计好坏影响^⑤。我们以构造正交矩条件为例来展示其威力，前两个用途的示例见 Ichimura and Newey (2022)。构造正交矩条件是最近几年大热的双重机器学习的两个基石之一（另一个是样本拆分），而这一切都离不开影响函数。关于影响函数在双重机器学习中所扮演角色的精彩介绍，见 Kennedy (2023)。

⑤ 这就是 Neyman 正交化。

假设我们有总体矩条件

$$\mathbb{E}_{F_0}[g(W, \gamma_0, \theta_0)] = 0$$

其中 $g(\cdot, \cdot, \cdot)$ 是形式已知的矩函数， γ_0 是未知的非参数部分， θ_0 是未知的参数部分。我们感兴趣的是对 θ_0 的估计。

如果我们用机器学习的算法获得了对 γ_0 的第一步估计 $\hat{\gamma}$ ，那么获得样本矩函数的一个最直接的方式就是直接代入 $\hat{\gamma}$ ，得到 $\sum_{i=1}^n g(W_i, \hat{\gamma}, \theta)/n$ ，然后对其使用 GMM 得到 θ_0 的估计量。然而，这种 plug-in 的方法会给 θ_0 的估计带来严重的偏误，因为我们的第一步估计 $\hat{\gamma}$ 本就不够精确——毕竟机器学习算法总是会用一些正则化手段来避免过拟合，从而带来较大的偏误。我们是否能重新构造一个矩条件，使得它不受第一步估计 $\hat{\gamma}$ 好坏的影响呢？答案是我们需要利用矩条件的影响函数。

记 $\hat{\gamma}$ 在数据分佈为 F 时的概率极限为泛函 $\gamma(F)$ ，从而 $\gamma_0 = \gamma(F_0)$ 。使用前文所介绍的 F_τ 形式的分佈扰动，假设存在一个函数 $\phi(w, \gamma, \alpha, \theta)$ ^⑥，使得对任意的 θ 和 H 都有

$$\left. \frac{\partial}{\partial \tau} \mathbb{E}_{F_0}[g(W, \gamma(F_\tau), \theta)] \right|_{\tau=0+} = \int \phi(w, \gamma_0, \alpha_0, \theta)H(dw) = \mathbb{E}_H[\phi(W, \gamma_0, \alpha_0, \theta)]$$

其中 $\mathbb{E}_{F_0}[\phi(W, \gamma_0, \alpha_0, \theta)] = 0$ 且 $\mathbb{E}_{F_0}[\phi(W, \gamma_0, \alpha_0, \theta)^2] < \infty$ 。这里的 ϕ 就是泛函 $\mu(F) := \mathbb{E}_F[g(W, \gamma(F), \theta)]$ 的影响函数，或者按照文献中的说法，称为「第一步影响函数」(first step influence function, FSIF)。

正交矩函数就可以构造为

$$\psi(W, \gamma, \alpha, \theta) = g(W, \gamma, \theta) + \phi(W, \gamma, \alpha, \theta)$$

⑥ 这里凭空出现的 α 其实是 $\theta(F)$ 的 EIF，是一个 Riesz 表示元。直觉上的理解就是，对原始矩函数的一阶校正项必定包含了模型扰动对参数估计本身的一阶影响，可以类比求导的链式法则。

即原矩条件加上其影响函数。这个做法事实上是利用了影响函数的梯度性质，将分布扰动的一阶影响加回去。显然有 $\mathbb{E}_{F_0}[\psi(W, \gamma_0, \alpha_0, \theta)] = 0$ 。

通常我们要求影响函数满足规范化条件，即任意扰动分布下都有零均值， $\mathbb{E}_{F_\tau}[\phi(W, \gamma(F_\tau), \alpha(F_\tau), \theta)] \equiv 0$ ，两边关于 τ 在 $\tau = 0^+$ 处求导：

$$\begin{aligned}
0 &\equiv \frac{\partial}{\partial \tau} \int \phi(W, \gamma(F_\tau), \alpha(F_\tau), \theta)[F_0 + \tau(H - F_0)](dw) \Big|_{\tau=0^+} \\
&= \frac{\partial}{\partial \tau} \int \phi(w, \gamma(F_\tau), \alpha(F_\tau), \theta)F_0(dw) \Big|_{\tau=0^+} + \int \phi(w, \gamma_0, \alpha_0, \theta)(H - F_0)(dw) \\
&= \frac{\partial}{\partial \tau} \mathbb{E}_{F_0}[\phi(W, \gamma(F_\tau), \alpha(F_\tau), \theta)] \Big|_{\tau=0^+} + \mathbb{E}_H[\phi(W, \gamma_0, \alpha_0, \theta)] \\
&= \frac{\partial}{\partial \tau} \mathbb{E}_{F_0}[\phi(W, \gamma(F_\tau), \alpha(F_\tau), \theta)] \Big|_{\tau=0^+} + \frac{\partial}{\partial \tau} \mathbb{E}_{F_0}[g(W, \gamma(F_\tau), \theta)] \Big|_{\tau=0^+} \\
&= \frac{\partial}{\partial \tau} \mathbb{E}_{F_0}[\psi(W, \gamma(F_\tau), \alpha(F_\tau), \theta)] \Big|_{\tau=0^+}
\end{aligned}$$

第二步利用了链式法则，第三步利用了 $\mathbb{E}_{F_0}[\phi(W, \gamma_0, \alpha_0, \theta)] = 0$ 。这个结论意味着 γ 的局部扰动不会影响矩条件的成立，也就达到了正交化的目的。

技术附录：泛函的可微性

本附录来自 [van der Vaart \(1991\)](#)，为泛函的可微性做出定义。泛函的导数是方向导数的一般化。

设 P 是一个概率测度，它对应真实的模型， $\mathcal{P}$ 是一个概率测度族，它包含了对 P 的某些偏离的概率测度，一个偏离以 P_t 表示， $t \in (0, \varepsilon) \subseteq \mathbb{R}$ 。令 $\mathcal{P}(P)$ 表示这种偏离路径的集合，即映射 $t \mapsto P_t$ 的集合，每个映射从一个区间 $(0, \varepsilon) \subseteq \mathbb{R}$ 映射到 $\mathcal{P}$ ，因此每个映射都代表了 P 的一个偏离路径，而且每一个偏离路径都需要满足：存在某个 $g \in L^2(P)$ 使得

$$\lim_{t \rightarrow 0^+} \int \left[\frac{1}{t} (dP_t^{1/2} - dP^{1/2}) - \frac{1}{2} g dP^{1/2} \right]^2 = 0$$

其中 dP_t 和 dP 分别是 P_t 和 P 的（关于某个支配测度的）密度函数。这个条件事实上对偏离路径 $t \mapsto P_t$ 做出了一些限制，它要求偏离路径具有某种意义上的光滑性。满足这个条件的路径也被称为「二次均值可微」(quadratic mean differentiability)。函数 g 相当于我们熟悉的得分函数^⑦。

从几何意义上说，得分函数 g 可以理解在 $t = 0$ 处切于偏离路径 $t \mapsto P_t$ 的一个切向量。这使得 $\mathcal{P}(P)$ 可以引致一个所谓的「切空间」(tangent space) $T(P)$ ，它是由所有满足上述条件的函数 g 张成的线性空间。

设 $(B, \|\cdot\|)$ 是一个巴拿赫空间^⑧。称泛函 $\kappa: \mathcal{P} \rightarrow (B, \|\cdot\|)$ 在 P 处相对于 $\mathcal{P}(P)$ 可微，如果它满足：存在一个连续的线性映射 $\kappa'_P: (T(P), \|\cdot\|_P) \rightarrow (B, \|\cdot\|)$ 使得对 $\mathcal{P}(P)$ 中的每一条路径 $t \mapsto P_t$ 及其相应的 $g \in T(P)$ 使得

$$\lim_{t \rightarrow 0^+} \frac{1}{t} [\kappa(P_t) - \kappa(P)] = \kappa'_P(g)$$

κ'_P 被称为 κ 在 P 处相对于 $\mathcal{P}(P)$ 的导数^⑨。这个导数是一个泛函，而且是连续的线性泛函，它将切空间 $T(P)$ 中的元素 g 映射为 $(B, \|\cdot\|)$ 中的元素 $\kappa'_P(g)$ 。连续线性是一个很关键的要求，只有这样才会有后面的 Riesz 表示。需要强调，这个定义不仅仅是定义左边极限的存在性，还说明了它能被表示成切空间上的泛函。

对于巴拿赫空间 B ，有其对偶空间 B^* ，它是由所有连续线性实值泛函 $b^*: B \rightarrow \mathbb{R}$ 构成的空间。对每个 $b^* \in B^*$ ，映射 $b^* \circ \kappa'_P$ 是从 $(T(P), \|\cdot\|_P)$ 到 $\mathbb{R}$ 的连续线性泛函。根据 Riesz 表示定理，存在一个唯一的 $\tilde{\kappa}_{P, b^*} \in \bar{T}(P)$ 使得，对每个 $g \in T(P)$ 都有^⑩

$$b^* \circ \kappa'_P(g) = \langle g, \tilde{\kappa}_{P, b^*} \rangle_P$$

特别地，对于正文中的泛函 $\theta(F_\beta)$ ，当 θ 是标量时， B 就是实数集 $\mathbb{R}$ ，因此我们就可以取 b^* 为恒等映射，于是存在一个唯一的 $\psi \in \bar{T}(F_0)$ 使得，对每个 $S_\beta \in T(F_0)$ 都有

$$\theta'(F_\beta) = \langle \psi, S_\beta \rangle_{F_0} = \mathbb{E}_{F_0}[\psi(W)S_\beta(W)]$$

这里的 Riesz 表示元 ψ 正是 EIF。

以下定理是对 Hájek-Le Cam 卷积定理的推广，见 [van der Vaart \(1991\)](#) 的定理 2.1。

定理 1. 设对任意路径 $\{P_t\} \in \mathcal{P}(P)$ 和实数列 $h_n \rightarrow h \in \mathbb{R}$ ，有

$$\sqrt{n}[T_n - \kappa(P_{h_n/\sqrt{n}})] \rightsquigarrow_{P_{h_n/\sqrt{n}}} L \quad (1)$$

⑦ 怎么理解？它可以看成 $dP_t^{1/2} - dP^{1/2} \approx \frac{t}{2} g dP^{1/2}$ 。为什么要用平方根密度呢？而且还带有一个 $1/2$ ？我们考虑普通的得分函数 $s(w) = \partial \log p_t(w)|_{t=0}$ ，对 $p_t(w)$ 在 $p_0(w)$ 处做一阶展开：

$$p_t(w) = p_0(w)[1 + t \cdot s(w) + o(t)]$$

两边开根号

$$\sqrt{p_t(w)} \approx \sqrt{p_0(w)} \left[1 + \frac{t}{2} s(w) \right]$$

所以（当似然函数可导时） g 就是得分函数。不过这里其实我们并不要求似然函数可导，因此 g 是更一般的得分函数。

⑧ 即完备的线性赋范空间。就我们考察的半参数问题而言，当参数 θ 是标量时， B 就是实数集 $\mathbb{R}$ ；当参数 θ 是向量时， B 就是欧几里得空间 $\mathbb{R}^k$ 。

⑨ 如果 $\mathcal{P}(P)$ 是所有满足前面光滑性条件的路径的集合，那么这个导数就是 Hadamard 导数。但一般情况下，比如在半参数模型中，由于模型限制，我们并不会考虑这么多的路径。

⑩ 通常我们还要加上规范化条件 $\mathbb{E}_P[\tilde{\kappa}_{P, b^*}] = 0$ 来保证唯一性，因为 $\mathbb{E}_P[g] = 0$ 。

其中 L 是 $\mathbf{B}$ 上的一个固定的紧密分布。此外，设对任意 $g \in T(P)$ 都有

$$\left(\sqrt{n}(T_n - \kappa(P)), n^{-1/2} \sum_{j=1}^n g(X_j) \right)$$

依 P 在 $\mathbf{B} \times \mathbb{R}$ 上联合弱收敛。那么 (i) $\kappa: \mathcal{P} \rightarrow (\mathbf{B}, \|\cdot\|)$ 在 P 处相对于 $\mathcal{P}(P)$ 可微，且 (ii) 存在一个 $\mathbf{B}$ 上的紧密的概率测度 N 满足：对任意 $b^* \in \mathbf{B}^*$

$$N \circ b^{*-1} = \mathcal{N}(0, \|\tilde{\kappa}_{P,b^*}\|_P^2)$$

即 N 是巴拿赫空间上的一个高斯分布，其由 b^* 投影到实数轴上的一维边缘分布都是均值为 0，方差为 $\|\tilde{\kappa}_{P,b^*}\|_P^2$ 的高斯分布。此外，极限分布 L 可以表示为 N 和另一个 $\mathbf{B}$ 上的一个概率测度的卷积。

这里，满足条件 (1) 的估计量 T_n 称为「正则」(regular) 估计量。这个条件和联合弱收敛条件一起保证了 κ 的可微性，且导数能表述成影响函数和得分函数的内积，见 van der Vaart (1991) 的引理 A.1。结论 (ii) 即卷积定理，描述了估计量的渐进效率下界， N 就代表了最优极限分布。

参考文献

- HAMPEL, F. R. (1974): “The Influence Curve and its Role in Robust Estimation,” *Journal of the American Statistical Association*, 69(346), 383–393.
- ICHIMURA, H. AND NEWEY, W. K. (2022): “The Influence Function of Semiparametric Estimators,” *Quantitative Economics*, 13(1), 29–61.
- KENNEDY, E. H. (2023): “Semiparametric Doubly Robust Targeted Double Machine Learning: A Review,” *arXiv preprint*, arXiv: 2203.06469.
- NEWEY, W. K. (1994): “The Asymptotic Variance of Semiparametric Estimators,” *Econometrica*, 62(6), 1349–1382.
- VAN DER VAART, A. (1991): “On Differentiable Functionals,” *Annals of Statistics*, 19(1), 178–204.